Многоплоскостной синтез фазовых голограмм

Данные, физическая оптимизация и нейросетевые модели

Nikolai Pautov Miroslav Makarov
Timofey Rumeev Maxim Kulyamin

8 ноября 2026 г.

Аннотация

Исследуется синтез одной фазовой маски размером 128×128 пикселей для формирования четырёх заданных изображений на расстояниях 24.1–27.7 мм. Сопоставляются три направления: обучение универсальной модели на смешанных целевых изображениях, подбор маски без предварительного корпуса и сочетание готовой сети с физической оптимизацией. В итоговом эксперименте на 24 четвёрках изображений и NVIDIA A100 сравниваются GS с 300 итерациями, GS с последующей оптимизацией Adam, заранее обученная развёрнутая сеть DUSFN и её уточнение через Adam. При общем бюджете около 2 с на маску GS $\rightarrow$ Adam даёт средние PCC/SSIM 0.5602/0.4156, а DUSFN $\rightarrow$ Adam — 0.5211/0.4730. Последний вариант выше по среднему SSIM, однако это преимущество зависит от поднабора и его бутстрэп-интервал на всех 24 примерах включает ноль. Готовая DUSFN работает за 20.7 мс при качестве 0.4515/0.3411. Архивные опыты с SIREN и Deep Decoder не показывают среднего преимущества над прямой оптимизацией фазы при одинаковом временном бюджете внутри каждого опыта. Представлены история смесей данных, независимая проверка сохранённых PNG и ограничения интерпретации. Результаты подтверждают работоспособность синтеза без предварительного датасета и пользу нейросетевой инициализации для отдельных режимов, но не устанавливают универсального победителя.

Ключевые слова: компьютерная голография, фазовый оптический элемент, дифракция Френеля, оптимизация фазы, развёрнутые сети, SIREN, смешанные данные.

1 Введение

Фазовый дифракционный оптический элемент изменяет пространственное распределение фазы когерентного поля. После распространения вклады разных участков апертуры интерферируют и формируют изображение. Для нескольких выходных плоскостей одна маска должна одновременно удовлетворять нескольким целевым распределениям. Улучшение изображения на одном расстоянии при этом может сопровождаться ухудшением на другом.

Классические итерационные методы, включая алгоритм Герчберга–Сэкстона (GS) [1], чередуют распространение поля и наложение ограничений. Это направленный поиск, а не перебор всех масок. Нейросетевые методы позволяют перенести часть вычислений на этап обучения [2, 3]. Другой подход использует архитектуру сети как представление одного искомого решения и подбирает её веса заново для каждого входа [4, 5, 6].

Развёртывание итерационного алгоритма в последовательность обучаемых блоков рассматривается и в современных исследованиях фазового восстановления. Например,

FourierGSNet использует упрощённые Fourier-итерации для передачи физической информации каскадной сети при сложном прямом операторе [7]. Это отдельная архитектура и другая экспериментальная постановка; её опубликованные показатели не используются как численный ориентир для нашей задачи.

В настоящей работе рассматривается задача хакатона по синтезу нейросетевого фазового элемента [8]. Основной вопрос состоит не только в выборе архитектуры, но и в согласовании данных, физического расчёта, функции ошибки и бюджета вычислений. Поэтому исследование разделено на три направления: предобучение на целевых изображениях, оптимизация без предварительного корпуса и гибридная схема с фиксированной сетью и последующим уточнением фазы.

Вклад работы имеет экспериментальный характер. Мы систематизируем использованные смеси данных, повторяем единое сравнение четырёх практических режимов и проверяем качество по сохранённым выходным файлам. Не заявляется новый общий алгоритм фазового восстановления или превосходство над современными методами на стандартном внешнем бенчмарке. Архивные серии рассматриваются как история поиска, а итоговый запуск — как отдельный контролируемый эксперимент.

2 Постановка задачи и физическая модель

2.1 Что требуется синтезировать

На вход поступают четыре одноканальных изображения $T_k \in [0,1]^{N\times N}$, $k = 1,\dots,4$, $N = 128$. Требуется найти фазу $\phi \in \mathbb{R}^{N\times N}$, для которой поле на модуляторе имеет вид

$$u_0(x,y) = \exp\bigl(i\phi(x,y)\bigr). \tag{1}$$

Амплитуда падающего поля считается равномерной; управление амплитудой, временное мультиплексирование и модель аппаратных искажений не используются. Оптические параметры приведены в табл. 1.

Таблица 1. Параметры задачи и естественная выходная сетка Single-FFT.

Параметр	Значение
Размер фазовой маски и каждой цели	128×128 пикселей
Длина волны λ	532 нм
Шаг пикселя модулятора Δx	10 мкм
Расстояния z_k	24.1; 25.3; 26.5; 27.7 мм
Выходной шаг $\Delta x'_k$	10.017; 10.515; 11.014; 11.513 мкм
Представление маски	8 бит: $0 \mapsto -\pi$, $255 \mapsto +\pi$

Для произвольных четырёх картинок точное совместное решение не гарантировано. Кроме того, добавление общей постоянной к фазе не меняет восстановленные амплитуды. Поэтому задача состоит в синтезе подходящей маски, а не в единственном восстановлении неизвестной «исходной голограммы».

2.2 Распространение и соглашение о яркости

Используется заданный в условиях одношаговый расчёт Френеля с одним двумерным преобразованием Фурье. После исключения множителей, не влияющих на нормированную амплитуду, дискретный оператор можно записать как

$$Q_k(x,y) = \exp\left[\frac{i\pi(x^2+y^2)}{\lambda z_k}\right], \tag{2}$$

$$\mathcal{P}_k(u_0) = \mathcal{F}_c\{u_0 Q_k\}, \qquad \Delta x'_k = \frac{\lambda z_k}{N\Delta x}, \tag{3}$$

где $\mathcal{F}_c$ — центрированное унитарное ДПФ. Координаты входной апертуры определены как $(n - N/2)\Delta x$. Выходная квадратичная фаза имеет единичный модуль, а общий масштаб исключается при нормировке. Поэтому их отсутствие в оценочном операторе не меняет сравниваемые изображения.

В итоговом командном оценщике используется изображение

$$R_k(\phi) = \frac{|\mathcal{P}_k(\exp(i\phi))|}{\max_{x',y'} |\mathcal{P}_k(\exp(i\phi))|}. \tag{4}$$

Это *нормированная амплитуда*. Физическая интенсивность пропорциональна $|U|^2$, и результаты нельзя автоматически переносить на оценку по интенсивности. Цели также один раз нормируются на собственный максимум отдельно для каждой плоскости.

Изображения сравниваются в индексах естественных выходных сеток (3). Их физический шаг различается с расстоянием. Подмена оператора на ASM, дополнительный padding или интерполяция в финальном сравнении не применяются. Это конкретная индексная постановка; сравнение на общей физической сетке потребовало бы отдельного протокола.

3 Рассматриваемые методы

3.1 GS и прямая оптимизация фазы

В многоплоскостном варианте GS поле переносится на четыре экрана, его амплитуда заменяется целевой, после чего поля возвращаются сопряжёнными операторами и суммируются. Фаза суммы задаёт следующий элемент:

$$\phi^{(t+1)} = \arg\left[\sum_{k=1}^{4} \mathcal{P}_k^*\left(\widetilde{T}_k \frac{\mathcal{P}_k(e^{i\phi^{(t)}})}{|\mathcal{P}_k(e^{i\phi^{(t)}})| + \varepsilon}\right)\right]. \tag{5}$$

В реализации $\widetilde{T}_k$ нормированы на среднеквадратичную амплитуду для согласования энергетического масштаба. Начальная фаза выбирается из равномерного распределения на $[-\pi, \pi]$ с фиксированным seed. Ориентир GS $\times 300$ выполняет 300 шагов.

В режиме GS $\rightarrow$ Adam лучший проверенный вариант GS служит стартом для прямого изменения N^2 пикселей фазы. Оптимизатор Adam [9] минимизирует

$$\mathcal{L}(\phi) = \frac{1}{4}\sum_{k=1}^{4} \left[1 - \mathrm{PCC}(R_k, T_k) + 1 - \mathrm{SSIM}(R_k, T_k)\right]. \tag{6}$$

Шаг начинается с 0.05 и уменьшается по косинусному расписанию в пределах доступного времени до 10% исходного значения; норма градиента ограничена значением 10. Фаза представлена свободным вещественным тензором: периодичность задаётся экспонентой в (1), а приведение диапазона выполняется при экспорте. Ограничивающая активация tanh для оптимизируемого тензора не нужна.

3.2 Готовая физическая сеть DUSFN и её уточнение

Обозначение DUSFN используется для обученной в данной серии модели. Это развёрнутая физическая сеть со свёрточными и спектральными блоками, а не стандартный U-Net. Спектральная ветвь выполняет преобразование Фурье, обучаемое смешивание каналов на выбранных частотах и обратное преобразование; подобный принцип применяется в Fourier Neural Operator [10].

Сначала сеть по четырём целевым амплитудам предсказывает четыре начальные фазы и выполняет обратное распространение на маску. Затем следуют шесть каскадов: прямой расчёт поля, оценка амплитудной невязки, её обратный перенос и обучаемая поправка к фазе. На вход поправки поступают действительная и мнимая части поля и обратно перенесённой невязки, текущая фаза и усреднённая невязка экранов. Ширина признаков равна 48, число спектральных мод — 32. Модель содержит около 75.85 млн вещественных параметрических компонент; комплексный вес при подсчёте считается двумя компонентами.

В финальном опыте загружаются лучшие сохранённые веса эпохи 11. В режиме DUSFN сеть выдаёт маску без изменения весов. В режиме DUSFN → Adam сеть служит инициализатором, после чего оптимизируются только пиксели полученной фазы по (6). Общая схема приведена на рис. 1. Сам по себе положительный результат гибрида ещё не доказывает преимущество только сетевой архитектуры: начальная фаза и число доступных шагов уточнения различаются.

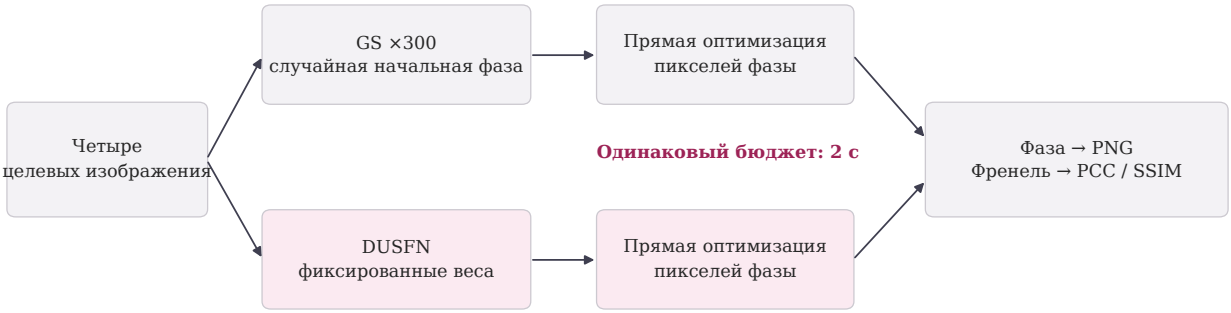


Рис. 1. Две инициализации одной физической задачи. Обе могут использоваться самостоятельно или с уточнением пикселей фазы. Веса готовой DUSFN в итоговом сравнении фиксированы.

3.3 Сети без предварительного корпуса

Идея Deep Image Prior состоит в использовании структуры сети как ограничения на представление изображения без обучения на большом наборе [4]. В исследуемых адаптациях сеть параметризует фазу одной маски, а её веса подбираются под текущую четвёрку.

В SIREN [6] входами служат нормированные координаты пикселя, выходом — скалярная фаза. Использованы четыре синусных слоя ширины 64 с частотным множителем 30 и линейная выходная голова. В адаптации Deep Decoder [5] фиксированный шум $16 \times 8 \times 8$ преобразуется четырьмя блоками билинейного увеличения разрешения, поканального смешивания 1×1, ReLU и нормировки; ширина равна 48. Пространственных свёрток 3×3 нет. Это собственная адаптация общего представления к фазовой задаче, а не точное воспроизведение опубликованного оптического метода.

Для выравнивания начальной маски использована параметризация $\phi = \phi_0 + g_\theta - g_{\theta_0}$, где ϕ_0 — общий плавный старт, а g_{θ_0} фиксирован. Для новой четвёрки веса подбираются

заново. Следовательно, «без датасета» означает отсутствие *предварительного корпуса*, а не отсутствие целевых данных или оптимизации во время решения.

4 Данные и эволюция обучающих смесей

4.1 От простых целей к смешанным наборам

В табл. 2 приведены подтверждённые размеры сохранённых выборок. Одна единица здесь — четвёрка, а не отдельная картинка. Для обучения через дифференцируемую физику нужны целевые изображения, но не обязательны эталонные фазовые маски: это позволяет использовать фотографии, символы и процедурную графику как входы [3].

Таблица 2. История данных. Размеры указаны в четвёрках: обучение / валидация / тест. Дополнительные диагностики не включены в эти три числа.

Набор	Размеры	Состав и назначение
Малый v1	320 / 48 / 10	Цифры, буквы, кольца, простая геометрия; начальная проверка метода.
Смешанный v2	4096 / 256 / 256	Fashion-MNIST, текст, фигуры, текстуры, точки и линии; четыре схемы размещения объектов.
Командная смесь	Генератор	50% слоёв сцены, 30% независимых фотографий, 20% объектов с фототекстурами.
Смешанный v3	10000 / 1000 / 1000	DIV2K, EMNIST, Fashion-MNIST и синтетические цели; дополнительно 400 диагностических четвёрок.
Диагностика-12	12 примеров	По четыре четвёрки фотографий, символов и плавных полей; без предварительного обучения на этом наборе.

В v2 источником предметных изображений служит Fashion-MNIST [11]. Свободные, плотные, квадрантные композиции и композиции с общими координатами расширяют набор взаимных расположений объектов. В v3 добавлены фотографии DIV2K [12], рукописные символы EMNIST [13], плавные поля и разные уровни фона. Фактический состав разделов показан на рис. 2; он вычислен по манифестам, а не принят равным желаемым вероятностям генератора.

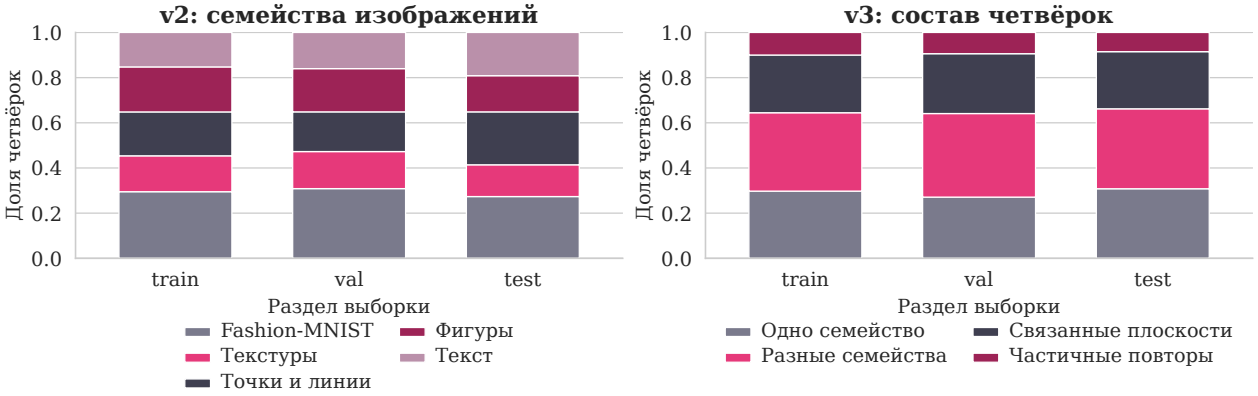


Рис. 2. Наблюдаемые частоты семейств v2 и способов формирования четвёрок v3. Доли относятся к готовым данным. Рецепт командной смеси 50/30/20 является отдельной вероятностной схемой и на рисунке не представлен как измеренный состав.

Важен не только источник отдельных картинок, но и связь четырёх экранов. В v3 используются независимые цели одного семейства, независимые цели разных семейств,

связанные плоскости и частично повторяющиеся цели. Связанные фото v3 выделяются по яркостным окнам одного изображения; это не истинная глубина сцены. Командные слои, полученные с использованием оценки глубины фотографии, относятся к другому генератору.

Ранний v2 разрабатывался с трактовкой яркости как интенсивности. В последующих опытах использована нормированная амплитуда (4). Поэтому расширение данных нельзя рассматривать как единственное изменение между этими сериями, а их численные метрики нельзя объединять в один рейтинг.

4.2 Итоговые 24 четвёрки

Для общего сравнения зафиксированы два поднабора. *Диагностика-12* содержит четыре четвёрки фотографий, четыре — символов и геометрии, четыре — плавных полей. Дополнительные 12 примеров выбраны из тестового раздела v3: по три на каждый из четырёх способов формирования четвёрки. Выбор выполнен до запуска решателей с seed 20261107. Все методы получают одни и те же пиксели после единой нормировки.

Это небольшой диагностический набор, а не случайная выборка из неизвестного распределения организаторов. Стратифицированные 12 примеров v3 также не воспроизводят естественные частоты полного теста. Они происходят из того же генератора, что и обучение DUSFN; отсутствие совпадений всех исходных фотографий диагностики с источниками предобучения не установлено. Поэтому качество публикуется отдельно по поднаборам, а общее среднее имеет описательный смысл.

5 Протокол оценки

5.1 Метрики, квантование и выбор маски

Для каждого экрана рассчитываются коэффициент корреляции Пирсона PCC и локальный индекс структурного сходства SSIM [14]. В SSIM используются гауссово окно 11×11, $\sigma = 1.5$, диапазон [0,1], популяционная ковариация и область полного окна; константы равны $C_1 = 0.01^2$, $C_2 = 0.03^2$. Это зафиксированный вариант SSIM; обозначение метрики без указания окна недостаточно для точного воспроизведения.

Сначала метрики усредняются по четырём плоскостям, затем по четвёркам. Отдельно для каждой четвёрки выбирается худшая плоскость; столбцы $\min_z$ в таблицах — средние этих минимумов, а не минимум по всему тесту. Четыре экрана одного входа не считаются четырьмя независимыми наблюдениями.

В итоговом эксперименте при экспорте фаза приводится по модулю 2π и кодируется:

$$q = \operatorname{round}\left[255\,\frac{(\phi + \pi) \bmod 2\pi}{2\pi}\right], \qquad \phi_q = \frac{2\pi q}{255} - \pi. \tag{7}$$

После повторного чтения `doe.png` выполняется распространение от ϕ_q, затем восстановления также сохраняются и перечитываются как 8-битные PNG. Все основные числа относятся к этим файлам.

Во время синтеза через каждые 10 шагов проверяется квантованное решение; сохраняется лучший проверенный вариант по $S = (\overline{\mathrm{PCC}} + \overline{\mathrm{SSIM}})/2$. GS $\times 300$ также использует лучший из проверенных вариантов, а не обязательно последний. Правило S является внутренним способом выбора, а не объявленной официальной агрегатной метрикой хакатона.

5.2 Временной бюджет и вычислительная среда

Итоговый запуск выполнен на NVIDIA A100-SXM4-40GB, Python 3.13.16, PyTorch 2.14.1+cu130, NumPy 2.4.6, с float32/complex64 и отключённым TF32. Для GS → Adam и DUSFN → Adam задан общий бюджет 2 с, включая инициализацию, создание оптимизатора и промежуточную оценку. Загрузка весов, общий прогрев, запись файлов и построение рисунков исключены из таймера. Порядок методов циклически меняется между входами.

Время проверяется раз в 10 шагов, поэтому возможен небольшой перерасход. Среднее фактическое время составляет 2.022 с и 2.019 с соответственно, максимальное — 2.041 с. GS-инициализация во всех случаях успела выполнить 300 шагов. Чистые GS и DUSFN являются ориентирами с собственным фактическим временем, а не методами с одинаковой двухсекундной длительностью. Для оценки скорости важно, что таймер включает принятый в данной реализации контроль качества; это не изолированный замер только FFT или только нейросетевого прохода.

5.3 Независимая проверка и неопределённость

Численный оператор проверен на сопряжённость, обратное преобразование, сохранение нормы, совпадение с прямой суммой ДПФ, корректность направленной производной и инвариантность к общей фазе. Отдельно все 96 сохранённых масок и 384 восстановления проверены через NumPy и независимую реализацию метрик. Максимальное расхождение PCC равно $1.8 \cdot 10^{-7}$, SSIM — $1.3 \cdot 10^{-4}$; расхождение нормированной амплитуды с PNG не превышает 0.001961, что соответствует округлению примерно на половину уровня яркости.

Для описания вариативности используются 10000 бутстрэп-перевыборок целых четвёрок с seed 20261107. Парные разности вычисляются между методами на одном входе. 95%-ные интервалы условны относительно выбранного малого набора; они не учитывают все случайные старты, повторные обучения, подбор гиперпараметров или неизвестное распределение будущих задач. На итоговых 24 примерах использован один seed решателя, поэтому эти интервалы не интерпретируются как доказательство универсального преимущества.

6 Результаты единого сравнения

6.1 Качество и время

Основные результаты приведены в табл. 3 и на рис. 3. GS → Adam достигает наибольшего среднего PCC, DUSFN → Adam — наибольшего среднего SSIM. Аналогичный компромисс сохраняется по среднему качеству худшей плоскости.

Таблица 3. Итоговый запуск: 24 четвёрки, A100. Значения после чтения PNG; время включает инициализацию и промежуточную оценку. Лучшие средние PCC и SSIM принадлежат разным методам.

Метод	PCC	SSIM	$\min_z$ PCC	$\min_z$ SSIM	Время, мс
GS ×300	0.5231	0.2394	0.3131	0.1690	175.2
GS → Adam	0.5602	0.4156	0.3526	0.2789	2022.1
DUSFN	0.4515	0.3411	0.2428	0.2536	20.7
DUSFN → Adam	0.5211	0.4730	0.3269	0.3399	2019.0

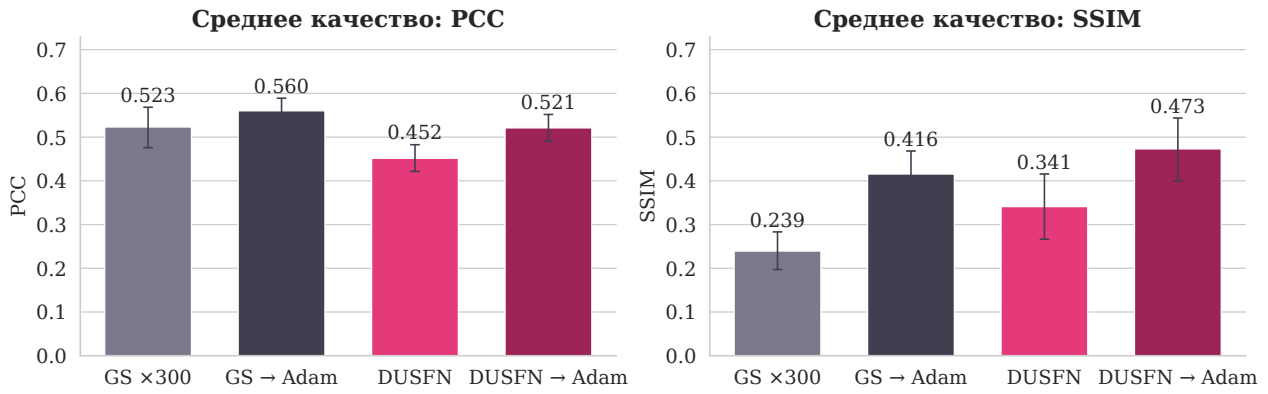


Рис. 3. Средние метрики по 24 четвёркам. Отрезки — 95%-ные бутстрэп-интервалы при перевыборке целых входных четвёрок. Они характеризуют вариативность данного набора, а не только численную погрешность.

Готовая DUSFN выдаёт результат в среднем за 20.7 мс против 175.2 мс у GS ×300 в данном протоколе. Это примерно 8.5-кратное сокращение времени, однако PCC снижается с 0.5231 до 0.4515, а SSIM повышается с 0.2394 до 0.3411. Следовательно, даже это сравнение не сводится к единственной шкале «лучше/хуже». Вычислительная цена первоначального обучения в эти времена не включена.

Уточнение выхода сети повышает PCC на 0.0696, SSIM — на 0.1320 относительно её самостоятельного прохода, но переводит решение в двухсекундный режим. Отношение качества и времени показано на рис. 4. На A100 за общий бюджет GS-гибрид выполнил в среднем 451.7 шага Adam после инициализации, нейросетевой гибрид — 488.3. Поэтому различие результатов включает как свойства старта, так и доступное количество шагов; сравнение с одинаковым числом итераций уточнения здесь отдельно не проводилось.

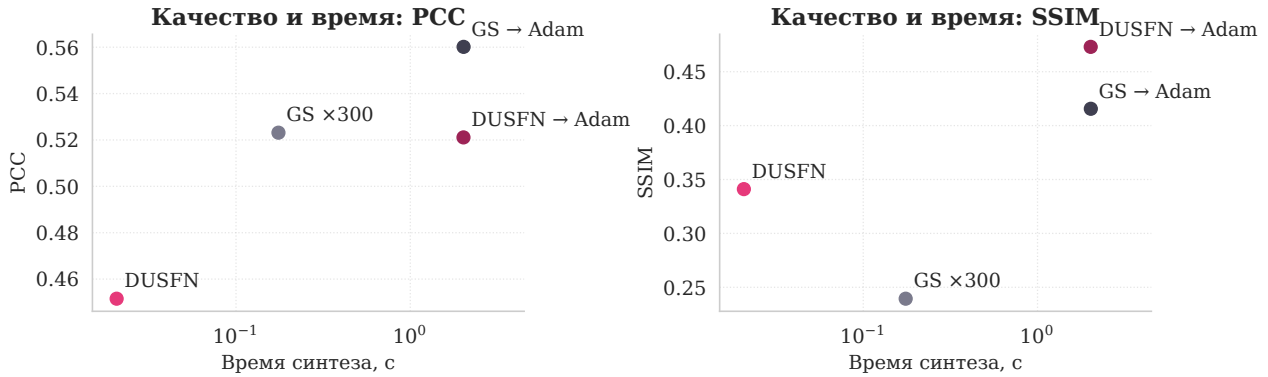


Рис. 4. Среднее качество и фактическая длительность синтеза. Время показано в логарифмической шкале. Чистые методы и двухсекундные гибриды отвечают разным требованиям к задержке.

6.2 Зависимость от типа целей

Общее преимущество нейросетевого гибрида по среднему SSIM формируется неодинаково на двух частях теста (табл. 4). На диагностике GS → Adam выше по обеим средним метрикам; на поднаборе v3 он выше по PCC, а DUSFN → Adam — по SSIM.

В табл. 5 приведены парные разности двух гибридов. Из результата DUSFN → Adam вычитается результат GS → Adam. На всех 24 входах среднее изменение PCC равно −0.0390, SSIM — +0.0574. Интервал SSIM включает ноль. На поднаборе v3 изменение SSIM достигает +0.1252, но это поднабор из того же генератора, на котором обучалась

Таблица 4. Раздельные результаты на двух поднаборах по 12 четвёрок. Эти оценки не следует заменять одной общей строкой при обсуждении переноса на новые цели.

Поднабор	Метод	PCC	SSIM
Диагностика-12	GS ×300	0.5736	0.2299
Диагностика-12	GS → Adam	0.5707	0.4154
Диагностика-12	DUSFN	0.4797	0.2882
Диагностика-12	DUSFN → Adam	0.5496	0.4051
v3: 12 примеров	GS ×300	0.4727	0.2489
v3: 12 примеров	GS → Adam	0.5496	0.4158
v3: 12 примеров	DUSFN	0.4234	0.3939
v3: 12 примеров	DUSFN → Adam	0.4926	0.5409

сеть. По отдельным четвёркам DUSFN-гибрид выше сразу по двум метрикам в 4 случаях, GS-гибрид — в 11; ещё в 9 случаях имеется компромисс.

Таблица 5. Парные различия гибридов. «Положительных» — число четвёрок с положительной разностью соответствующей метрики. Интервалы описательные, без коррекции на множественные сравнения.

Поднабор	Метрика	Δ	95% интервал	Положительных
Все 24	PCC	-0.0390	[-0.0519; -0.0262]	4/24
Все 24	SSIM	+0.0574	[-0.0041; +0.1196]	13/24
Диагностика-12	PCC	-0.0211	[-0.0350; -0.0085]	3/12
Диагностика-12	SSIM	-0.0103	[-0.0817; +0.0665]	4/12
v3: 12 примеров	PCC	-0.0570	[-0.0719; -0.0390]	1/12
v3: 12 примеров	SSIM	+0.1252	[+0.0466; +0.2111]	9/12

Такая зависимость согласуется с влиянием обучающего распределения, но не изолирует его причинно. Для причинного вывода потребовалось бы обучить одну архитектуру на разных смесях при одинаковых настройках и проверить её на независимых источниках.

6.3 Визуальный результат

На рис. 5 показан заранее фиксированный пример `photos_00`. Восстановления демонстрируют как структуру целевого изображения, так и вклад других экранов. Нормировка на максимум не устраняет спекл и взаимные помехи. Дополнительный пример с символами приведён в приложении C; он особенно наглядно показывает, почему высокий SSIM или PCC в отдельности не гарантирует чистого восстановления. Примеры не выбирались по максимальному качеству метода.

7 Архивные эксперименты и развитие решения

7.1 Обучение на смешанных данных

В командной серии использовались прямое предсказание маски и сети поправок к физическому решению [15]. Модель M2 формирует маску одним проходом; M10 сочетает GS ×20 с тремя обученными шагами; M10p использует начальное ядро GS с весами и обратной связью и обучение на смеси 50/30/20. Часть ранних прямых моделей строилась вокруг

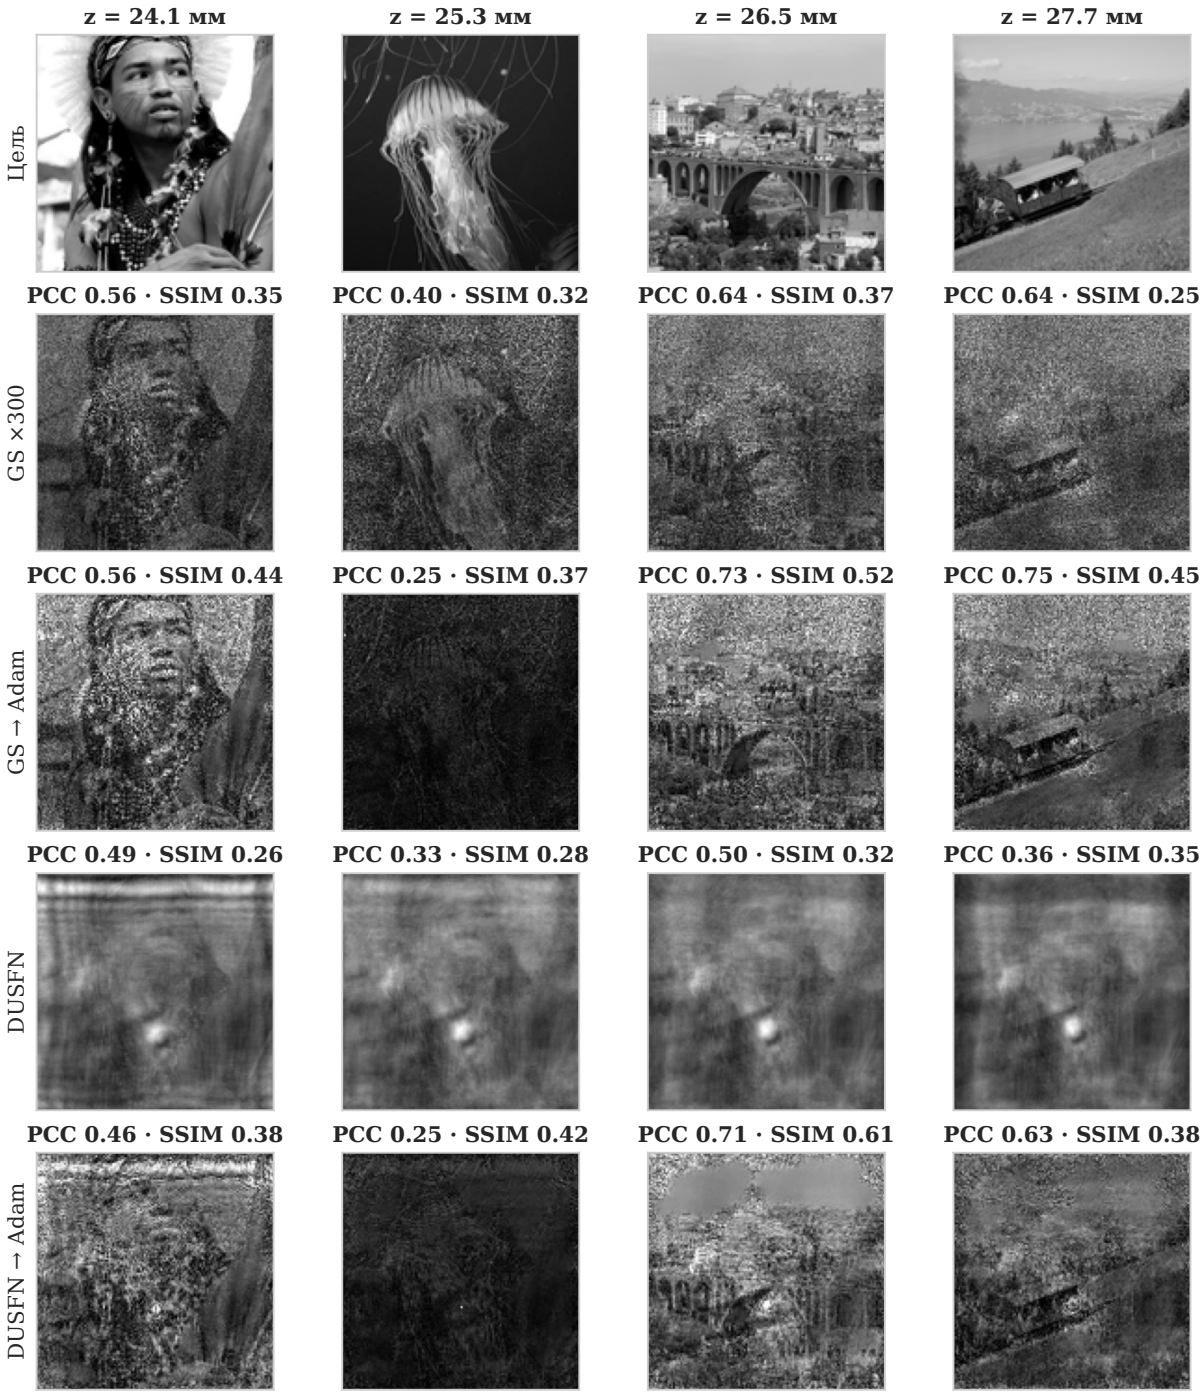


Рис. 5. Восстановления фиксированной четвёрки `photos_00`. Сверху — цели, далее четыре метода; столбцы соответствуют четырём расстояниям. Яркость во всех панелях показана в шкале [0,255]. В подписях указаны PCC и SSIM каждой плоскости.

свёрточных архитектур типа U-Net, однако названия M2/M10/M10p здесь относятся к конкретным конфигурациям командного кода.

В свежем архивном тесте на 32 четвёрках каждого типа M10p улучшает результат M10 во всех трёх группах (табл. 6). Однако одновременно изменились начальный алгоритм и смесь данных. Поэтому эти числа подтверждают результат всей конфигурации, а не отдельный эффект расширения датасета. На «реализуемых» целях — полученных прямым расчётом от известной маски — GS ×300 выше M10p по обеим метрикам. На слоях сцены обученные поправки могут увеличить SSIM ценой PCC.

Таблица 6. Отдельный командный тест: по 32 четвёрки в группе, PCC / SSIM. Это другой набор; строки не являются прямым сравнением с итоговыми 24 примерами.

Метод	Слои сцены	Независимые	Реализуемые
GS ×300	0.4269 / 0.1645	0.5183 / 0.3378	0.7465 / 0.6298
GS+ ×300	0.4275 / 0.1723	0.5235 / 0.3512	0.7294 / 0.6106
M2	0.3113 / 0.1142	0.2301 / 0.1287	0.3001 / 0.1916
M10	0.3927 / 0.1810	0.4656 / 0.3087	0.6568 / 0.5234
M10p	0.3945 / 0.1862	0.4886 / 0.3311	0.7099 / 0.5519
GS+ → Adam	0.3873 / 0.2012	0.4928 / 0.3538	0.7193 / 0.6177

Полный архивный тест DUSFN содержит 1000 четвёрок v3 и даёт PCC/SSIM 0.3981/0.4098. Распределение по семействам и ход обучения показаны на рис. 6. Для текстовых целей SSIM достигает 0.4937 при PCC 0.1699, тогда как для связанных фото PCC равен 0.5105 при SSIM 0.3696. Эти различия делают просмотр изображений и анализ состава выборки необходимой частью оценки.

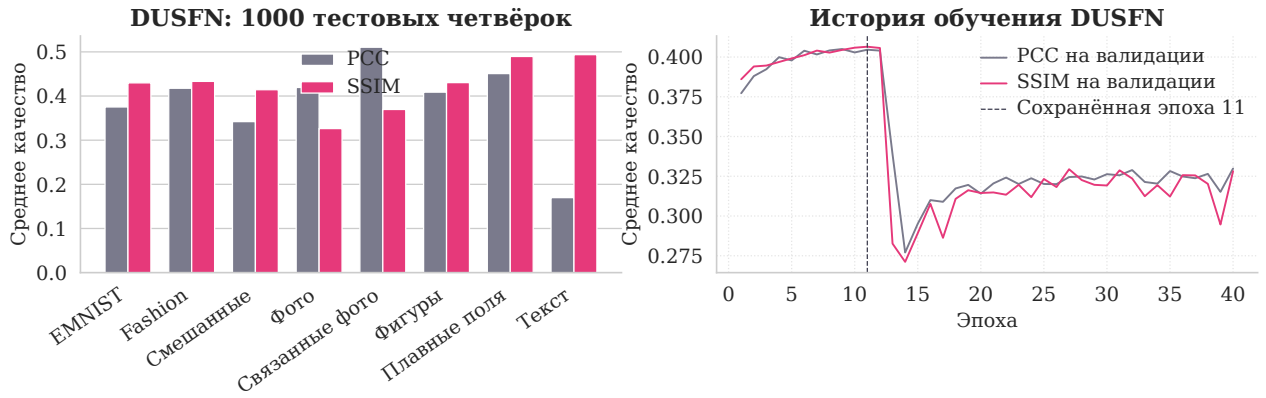


Рис. 6. Архив DUSFN: качество по семействам полного теста и валидационные кривые. После 12-й эпохи наблюдается резкое ухудшение; используются сохранённые веса эпохи 11. По одной кривой причина ухудшения не устанавливается.

Сохранённая конфигурация обучения указывает 40 эпох, AdamW с шагом 0.0015 и weight decay 10^{-4}, batch size 32 и micro-batch size 1; планировщик шага не использовался. Выбор лучшей эпохи выполнялся по сохранённому валидационному критерию, учитывающему среднее качество и худшую плоскость. В итоговом сравнении обучение не повторялось. Небольшая архивная проверка DUSFN против классических методов на восьми входах вынесена в приложение A; она не подменяет полный тест.

7.2 Проверка нейросетевых представлений без предобучения

SIREN и Deep Decoder проверены на диагностике из 12 четвёрок с двумя случайными стартами. SIREN запускалась на A100, Deep Decoder — на L4. Внутри каждого опыта нейросеть и физические ориентиры использовали один ускоритель и бюджет около 15 с, кроме отдельного GS ×300. Число независимых входов равно 12, а не 24: два старта одного примера усредняются до межметодного сравнения.

Результаты приведены в табл. 7. SIREN достигает 0.5235/0.3768 против 0.5710/0.4434 у её GS → Adam. Deep Decoder даёт 0.4839/0.3430 против 0.5709/0.4439 у собственного физического ориентира. На отдельных плавных целях возможны улучшения, но среднего выигрыша по двум метрикам нет (рис. 7). Эти наблюдения относятся к данным архитектурам, гиперпараметрам и временному ограничению; они не являются опровержением всех необученных нейросетевых представлений.

Таблица 7. Архивные опыты без предварительного корпуса: среднее по 12 четвёркам после усреднения двух стартов. Сравнивать SIREN и Deep Decoder между собой как один аппаратно равный тест нельзя.

GPU	Метод	PCC	SSIM	Время, с
A100	GS ×300	0.5695	0.2319	0.165
A100	GS: 15 с	0.5896	0.2501	15.005
A100	Прямой Adam	0.5744	0.4068	15.044
A100	GS → Adam	0.5710	0.4434	15.037
A100	SIREN	0.5235	0.3768	15.074
L4	GS ×300	0.5695	0.2319	0.163
L4	GS: 15 с	0.5896	0.2502	15.005
L4	Прямой Adam	0.5748	0.4069	15.046
L4	GS → Adam	0.5709	0.4439	15.035
L4	Deep Decoder	0.4839	0.3430	15.051

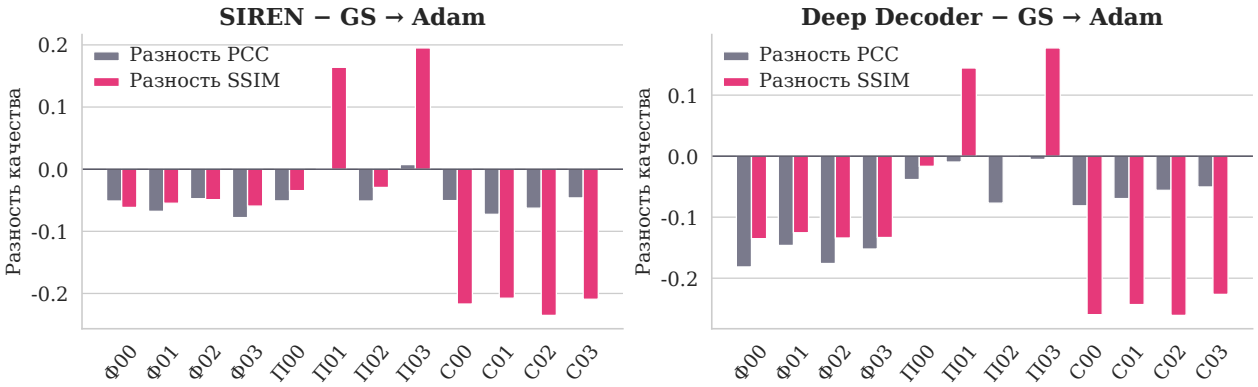


Рис. 7. Парные изменения относительно GS → Adam внутри каждого архивного опыта. Ф — фото, С — символы, П — плавные поля. Нулевой уровень означает равное качество. Общий отрицательный результат не исключает отдельных успешных входов.

8 Обсуждение и ограничения

8.1 Какие выводы подтверждены

Предварительные фазовые ответы для корпуса не обязательны: модель можно обучать через прямую физику. Предварительный корпус также не обязателен для подбора одной маски: GS и прямая оптимизация работоспособны только с текущими четырьмя целями. При этом отсутствие корпуса не делает нейросетевую параметризацию автоматически более эффективной, чем прямой тензор фазы.

Предобучение решает другую задачу — уменьшает задержку синтеза новой маски. В нашем протоколе DUSFN даёт быстрый самостоятельный результат и полезную для части целей инициализацию уточнения. При двухсекундном ограничении финальный выбор зависит от требуемой метрики: GS → Adam сохраняет преимущество по среднему PCC, DUSFN → Adam — по среднему SSIM на объединённом наборе. На диагностике последний средний выигрыш исчезает. Поэтому выражение «лучший алгоритм» требует заранее определить допустимое время, тип входов и правило агрегирования качества.

Условия хакатона предусматривают нейросетевой метод. Самостоятельный GS → Adam служит сильным физическим ориентиром, но не становится нейросетью от использования PyTorch. В рамках этого требования кандидатом остаётся готовая DUSFN или её сочетание с оптимизацией фазы; физический ориентир позволяет оценить, какой выигрыш действительно даёт модель.

8.2 Границы обобщения

Все результаты получены численно. Не проверялись калибровка реального модулятора, неравномерность лазерного пучка, оптическая эффективность, абсолютная энергия по плоскостям и соответствие камеры нормированной амплитуде. Независимая нормировка каждого экрана может скрывать различия абсолютной мощности.

Итоговый набор мал, один запуск решателя не оценивает вариативность всех стартов, а обученная модель не переобучалась несколько раз. Влияние смеси данных не изолировано от изменения архитектуры и начального физического ядра. Равное время не означает равного числа шагов, как и равное число шагов не означает равных затрат. Использованное внутреннее правило выбора маски одинаково для методов, но само задаёт компромисс между PCC и SSIM.

Архитектуры с attention и трансформерами рассматривались как отдельное направление поиска литературы. Представленные эксперименты не содержат полноценного контролируемого сравнения, позволяющего связать улучшение с механизмом внимания. Аналогично, литературные результаты для разреженных сцен, шумоподавления или восстановления измеренного поля не переносятся автоматически на четыре произвольных плотных цели.

9 Заключение

Систематизирована серия опытов по синтезу одной фазовой маски для четырёх выходных плоскостей. История данных включает простую процедурную графику, смешанный v2, фотографии и слои сцены, а также расширенный v3. Увеличение разнообразия данных само по себе не доказало причинного улучшения, поскольку нередко сопровождалось изменением алгоритма.

Единый запуск на A100 выявил практический компромисс. При бюджете около 2 с GS → Adam дал PCC/SSIM 0.5602/0.4156, DUSFN → Adam — 0.5211/0.4730; самостоятельная сеть работала за 20.7 мс с качеством 0.4515/0.3411. Преимущество гибрида по SSIM зависит от поднабора и не сопровождается преимуществом по PCC. SIREN и Deep Decoder в архивных ограниченных по времени опытах не превзошли прямую физическую оптимизацию в среднем.

Практическое решение состоит в сохранении двух линий: физического подбора как обязательного ориентира и готовой физической сети как быстрого нейросетевого метода с возможным уточнением. Следующим контролируемым опытом должно стать раздельное изменение только смеси данных либо только инициализации, с проверкой на независимых источниках и нескольких запусках. До такой проверки универсальная победа конкретной архитектуры не установлена.

Материалы и воспроизводимость

Итоговый расчёт оформлен в `01_photonic_solution.ipynb`; история данных и перерасчёт архивных опытов — в `02_data_and_experiments.ipynb`. Небольшой `photonic_data.zip` содержит необходимые цели и исходные таблицы. Архивы запусков сохраняют маски, восстановления, метрики по каждому входу, траектории уточнения и параметры среды. Веса DUSFN не включены в сопроводительный архив статьи: её повторный вывод требует отдельно предоставленного checkpoint. Анализ сохранённых результатов и физические методы доступны без этих весов. Исходная командная реализация зафиксирована на версии репозитория [15]; новые числа получены в запуске `20261107_204741` и независимо проверены по PNG.

Список литературы

[1] Gerchberg R. W., Saxton W. O. A practical algorithm for the determination of phase from image and diffraction plane pictures. *Optik*. 1972. Vol. 35. P. 237–246.

[2] Horisaki R., Takagi R., Tanida J. Deep-learning-generated holography. *Applied Optics*. 2018. Vol. 57. P. 3859–3863. DOI: 10.1364/AO.57.003859.

[3] Eybposh M. H., Caira N. W., Atisa M., Chakravarthula P., Pégard N. C. DeepCGH: 3D computer-generated holography using deep learning. *Optics Express*. 2020. Vol. 28. P. 26636–26650. DOI: 10.1364/OE.399624.

[4] Ulyanov D., Vedaldi A., Lempitsky V. Deep Image Prior. *CVPR*. 2018. arXiv:1711.10925.

[5] Heckel R., Hand P. Deep Decoder: Concise Image Representations from Untrained Non-convolutional Networks. *ICLR*. 2019. arXiv:1810.03982.

[6] Sitzmann V., Martel J. N. P., Bergman A. W., Lindell D. B., Wetzstein G. Implicit Neural Representations with Periodic Activation Functions. *NeurIPS*. 2020. arXiv:2006.09661.

[7] Yan S., Holenderski M. J., Meratnia N. Efficient Gerchberg–Saxton algorithm deep unrolling for phase retrieval with a complex forward path. *Advanced Photonics Nexus*. 2026. Vol. 5, no. 2. 026005. DOI: 10.1117/1.APN.5.2.026005.

[8] Лаборатория «Фотоника и информационная оптика», кафедра № 37 «Лазерная физика». *Разработка нейросетевого метода синтеза дифракционных оптических элементов.* Презентация задания хакатона. Москва, 2026. 7 с.

[9] Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization. *ICLR*. 2015. arXiv:1412.6980.

[10] Li Z., Kovachki N., Azizzadenesheli K. et al. Fourier Neural Operator for Parametric Partial Differential Equations. *ICLR*. 2021. arXiv:2010.08895.

[11] Xiao H., Rasul K., Vollgraf R. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. 2017. arXiv:1708.07747.

[12] Agustsson E., Timofte R. NTIRE 2017 Challenge on Single Image Super-Resolution: Dataset and Study. *CVPR Workshops*. 2017. Страница набора DIV2K.

[13] Cohen G., Afshar S., Tapson J., van Schaik A. EMNIST: an extension of MNIST to handwritten letters. 2017. arXiv:1702.05373.

[14] Wang Z., Bovik A. C., Sheikh H. R., Simoncelli E. P. Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*. 2004. Vol. 13. P. 600–612. DOI: 10.1109/TIP.2003.819861.

[15] Makarov M. et al. *atom-hack-photonic*: код и результаты командных экспериментов. 2026. Версия `0a58e30`. GitHub: зафиксированная версия.

A Дополнительная архивная проверка DUSFN

Таблица 8 относится к восьми общим примерам из архивной серии на A100. Она показывает, почему готовая сеть первоначально была интересна как быстрый инициализатор: DUSFN выше GS ×300 по обеим средним метрикам, а дополнительное уточнение улучшает PCC. При этом прямой Adam ×200 выше по SSIM. Эти восемь примеров нельзя смешивать с полным тестом на 1000 четвёрках или новым набором из 24 входов. Времена и настройки взяты из сохранённой серии, а не измерены повторно.

Таблица 8. Архивная проверка на восьми четвёрках.

Метод	PCC	SSIM	Время, мс
GS ×300	0.3570	0.2770	129.16
Adam ×200	0.3631	0.4734	795.00
GS ×20 → Adam ×15	0.3548	0.3832	68.60
DUSFN	0.3744	0.4347	20.16
DUSFN → Adam ×15	0.4073	0.4386	80.48

B Параметры итогового сравнения

Таблица 9. Настройки воспроизведения. Две архивные серии по 15 с имеют собственные параметры и не заменяются этим протоколом.

Компонент	Настройка
Входы	24 четвёрки, $4 \times 128 \times 128$, нормировка на максимум каждого экрана
Выбор поднабора v3	По 3 примера четырёх типов композиции, seed 20261107
Случайный старт GS	Равномерная фаза на $[-\pi, \pi]$, seed 42
GS в итоговом гибриде	300 шагов; лучший проверенный квантованный вариант
Adam	Шаг 0.05; косинусное уменьшение до 0.005; ограничение нормы градиента 10
Бюджет гибридов	2 с с инициализацией и контролем качества; проверка раз в 10 шагов
Число шагов уточнения	GS-гибрид: 430–470; DUSFN-гибрид: 480–500
Выбор маски	Максимум среднего $(\mathrm{PCC} + \mathrm{SSIM})/2$ среди проверенных вариантов
Квантование	Фаза и восстановления сохраняются как 8-битные PNG
Веса сети	Эпоха 11; при итоговом запуске не изменяются
Точность вычислений	float32 / complex64, TF32 выключен; проверки оператора в float64
Бутстрэп	10000 перевыборок целых четвёрок, seed 20261107

C Восстановление символов и взаимные помехи

Пример `symbols_00` относится к фиксированной диагностике. Во всех плоскостях различимы признаки других целей: оптимизация распределяет ошибку между четырьмя экранами, а не устраняет физическую связь между ними. DUSFN в этом примере воспроизводит сходную размытую структуру на нескольких расстояниях; уточнение фазы меняет компромисс. Отдельная метрика не заменяет такой визуальной проверки.

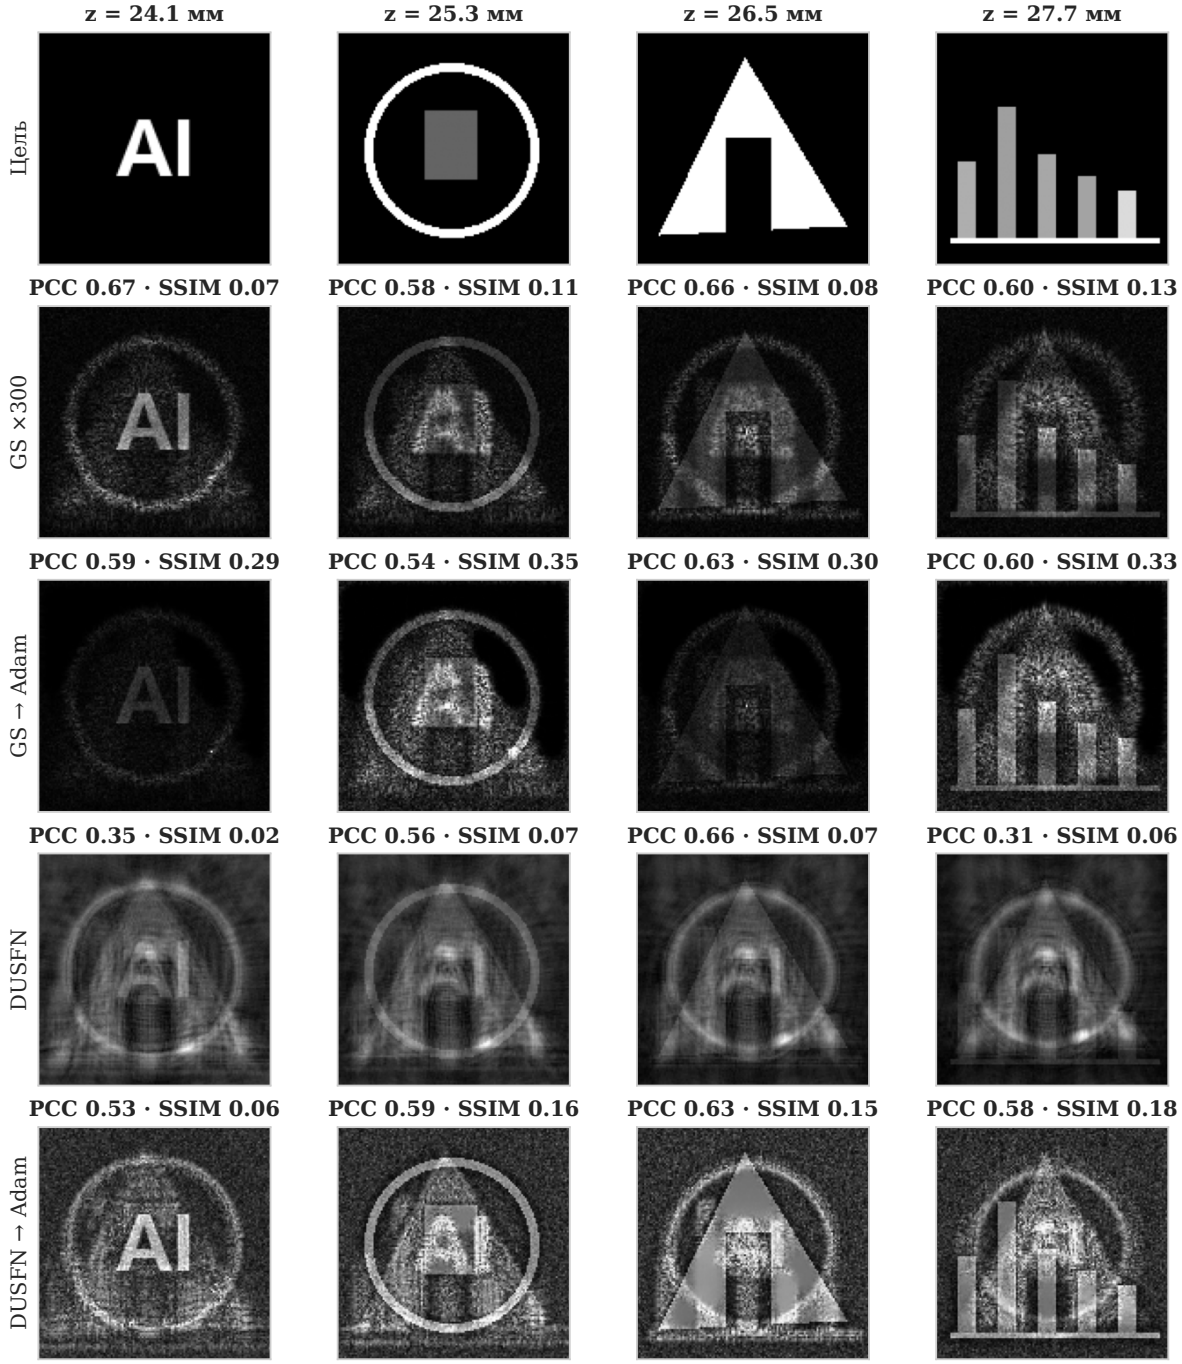


Рис. 8. Фиксированный пример `symbols_00`; порядок строк и шкала яркости соответствуют рис. 5. Значения относятся к сохранённым PNG.